

Progetto di Machine Learning Advanced

Obiettivo e dataset

Obiettivo:

predire la progressione del diabete dopo un anno.

Dataset utilizzato:

Diabetes dataset di Scikit-Learn.

Caratteristiche:

- 442 osservazioni
- 10 variabili cliniche
- 1 variabile target
- **nessun** valore mancante



Il dataset è già standardizzato, quindi non è stato necessario applicare ulteriori tecniche di scaling.

Analisi esplorativa: risultati principali



Principali evidenze:

- BMI mostra la correlazione più elevata con il target (0.59)
- S5 presenta una forte correlazione positiva (0.57)
- Non sono presenti valori mancanti
- Gli outlier individuati risultano limitati

BMI e S5 risultano le variabili maggiormente associate alla progressione del diabete e saranno quindi particolarmente rilevanti nella fase di modellazione.

Preprocessing

Preprocessing:

- Dataset già standardizzato
- Medie vicine a 0
- Deviazioni standard simili
- Nessuno scaling aggiuntivo necessario
- Outlier mantenuti

Baseline

Modello baseline:

Linear Regression

$$R^2 = 0.453$$

La baseline è stata usata come riferimento per valutare il miglioramento del modello finale.

Decisione metodologica

Dopo il preprocessing, la Linear Regression è stata scelta come baseline per verificare se Random Forest producesse un miglioramento reale.

Modello finale e confronto

Modello finale:

Random Forest Regressor

Ottimizzazione:

GridSearchCV con validazione incrociata a 5 fold

Migliori iperparametri:

- `n_estimators` = 200
- `max_depth` = 3

Confronto $R^2 \times 1000$



Random Forest ottiene un R^2 leggermente superiore rispetto alla baseline.

*Linear Regression = 0.453
Random Forest = 0.476*

Prestazioni Random Forest:


$$R^2 = 0.476$$

$$\text{MAE} = 42.714$$

$$\text{RMSE} = 52.672$$

Random Forest mostra un miglioramento rispetto alla baseline.

Il miglioramento è contenuto, ma indica una migliore capacità di catturare relazioni non lineari nei dati.



Conclusioni

Il progetto ha seguito una pipeline completa:

- Analisi esplorativa dei dati
- Valutazione del preprocessing
- Creazione di una baseline
- Ottimizzazione del modello finale
- Valutazione delle prestazioni

BMI e S5 sono risultate le variabili più associate alla progressione del diabete.

Random Forest Regressor ha ottenuto un R^2 pari a 0.476, leggermente superiore alla Linear Regression.

Il modello offre una base utile per l'analisi predittiva, pur lasciando spazio a futuri miglioramenti.



Notebook completo disponibile
tramite il link Google Drive: [Jupyter Notebook](#)